
PEMROGRAMAN INTERNET 2



Disusun Oleh:

Arya Sheva Putra Wijaya	24782071
Naufal Alfathan Hafizh	24782088
Ragil Afda Tripradana	24782091
Wahyu Tirta Wardana	24782096

Dosen:

Ir. Nurul Qomariyah, M.Kom.

Ir. Dian Ayu Afifah, S.Si., M.Sc.

TEKNOLOGI REKAYASA INTERNET

JURUSAN TEKNOLOGI INFORMASI

POLITEKNIK NEGERI LAMPUNG

2026

LAPORAN PERANCANGAN SMART DIGITAL PRODUCT: HOAXSCAN

Sistem Pendeteksi Berita Hoax Berbasis Kecerdasan Buatan Hybrid dengan Analisis
Multimodal Teks, Gambar, dan Video

1. Ringkasan Eksekutif

Masalah: Satu link berita hoax kerap membawa beberapa bentuk sekaligus, mulai dari klaim tertulis, foto yang diambil dari peristiwa lain, sampai video yang dipotong konteksnya, sementara alat verifikasi yang tersedia umumnya hanya membaca teksnya lalu berhenti pada cap “hoax” atau “fakta” tanpa alasan yang bisa ditelusuri.


Solusi Digital: Aplikasi web yang menerima satu link berita, menggali teks beserta gambar dan video pada halaman yang sama, lalu menilainya lewat dua tahap: IndoBERT hasil fine-tuning untuk penyaringan cepat atas teks, dan Gemini yang melihat langsung gambar serta videonya sambil menalar dengan rujukan hasil pencarian RAG. Pengguna mendaftar dan login dengan akun pribadi, sehingga setiap pemeriksaan tersimpan di riwayat yang bisa dicari kembali.

Target Pengguna: Warga yang menerima kiriman link mencurigakan lewat WhatsApp atau media sosial, serta jurnalis yang butuh penyaringan awal sebelum melakukan verifikasi manual.

2. Arsitektur Sistem

Alur berjalan satu arah dan hanya satu layanan pihak ketiga yang dipanggil, yaitu Gemini; selebihnya backend hanya men-download halaman dan media dari server penerbit berita. Modul scraping, classifier, retrieval, dan agregasi hidup dalam proses Python yang sama serta berbagi memori, sehingga tidak ada antrian pesan maupun orkestrasi container yang perlu diurus. Monolit modular ini kami pilih karena tim berjumlah empat orang dan proyeknya harus bisa dijalankan siapa saja dengan satu perintah; memecahnya jadi layanan terpisah hanya menambah pekerjaan integrasi tanpa menambah kemampuan apa pun di skala sekecil ini.

2.1 Diagram Arsitektur



Gambar 1. Topologi HoaxScan. Satu backend mengorquestrasi scraping, penilaian hybrid, akun, dan penyimpanan; satu-satunya layanan pihak ketiga yang dipanggil adalah Gemini.

2.2 Spesifikasi Teknologi (Tech Stack)

- **Perangkat Keras/Sensor:** Tidak ada. HoaxScan tidak membaca sensor dan tidak butuh perangkat tambahan apa pun; satu-satunya masukan berupa link yang ditempel pengguna di browser, dan seluruh pemrosesan berjalan di sisi server.
- **Backend & API:** FastAPI di atas Python 3.13 yang dijalankan Uvicorn. Penyimpanan memakai SQLite lewat SQLAlchemy ORM, sebab satu file database yang bisa dikirim antar anggota tim jauh lebih praktis ketimbang menyiapkan server PostgreSQL untuk proyek satu semester. Pydantic menjaga bentuk request dan response di batas API. Library pendukung scraping: requests untuk men-download HTML dan gambar, newspaper3k untuk membaca HTML itu menjadi isi artikel sekaligus menemukan link gambar dan

video, yt-dlp untuk men-download file video, serta langdetect untuk memeriksa bahasa. Tiap tugas dipegang satu library saja. Akun pengguna disimpan di database yang sama, dengan password hanya dalam bentuk hash (bcrypt sebagai kandidat algoritmanya), dan API key dibaca dari file .env lewat python-dotenv sehingga tidak ikut masuk repository.

- **Kecerdasan Buatan/Algoritma/Model/Dataset:**

- IndoBERT (indobenchmark/indobert-base-p1) yang di-fine-tune untuk klasifikasi biner hoax dan fakta. Berjalan lokal, tanpa biaya per request, dan hanya membaca teks.
- Dataset latih “Indonesian Fact and Hoax Political News” dari Kaggle, berisi artikel berita utuh (bukan cuitan pendek): artikel fakta dari CNN Indonesia, Kompas, dan Tempo, berbanding artikel hoax hasil klarifikasi Turnbackhoax, dengan jumlah artikel fakta jauh lebih banyak. Deskripsi dataset di Kaggle menyebut MIT License, tetapi lisensi itu dipasang uploader dataset dan belum tentu mencakup hak cipta artikel aslinya, sehingga dataset hanya dipakai untuk melatih model dan artikelnya tidak ditampilkan ulang.
- Google Gemini model Flash sebagai penilai multimodal. Gambar dikirim sebagai bytes, video di-upload lewat Files API, keduanya masuk ke satu prompt bersama teks artikel, lalu dijawab dalam JSON. File video dihapus dari server sendiri dan dari Google begitu penilaian selesai. Pada free tier, syarat layanan Google menyatakan input dan output boleh dibaca human reviewer dan melarang pengiriman data pribadi atau rahasia, sedangkan paid tier tidak memakai data itu untuk meningkatkan produk Google. Free tier juga tidak boleh dipakai pada aplikasi yang kemungkinan besar diakses pengguna di bawah 18 tahun, jadi hal ini harus disikapi sebelum HoaxScan dibuka untuk publik.
- sentence-transformers paraphrase-multilingual-MiniLM-L12-v2 untuk pencarian rujukan. Korpus cek-fakta di-encode sekali lalu disimpan, dan tiap klaim baru dibandingkan memakai cosine similarity.

Dataset dan base model yang sama pernah dipakai Fathin dkk. (2024, Jurnal Media Informatika Budidarma) untuk fine-tuning IndoBERT serupa, dengan akurasi 97,6% pada data asli dan naik ke 98,2% setelah random undersampling. Angka itu kami jadikan rujukan awal, bukan jaminan hasil kami akan sama: dari confusion matrix yang mereka lampirkan, recall khusus kelas hoax sebenarnya sekitar 92,8%, bukan 96% seperti akurasi gabungan yang dilaporkan di teks, sebab performa kelas fakta yang jauh lebih banyak datanya mendominasi rata-rata. Kami akan tetap melaporkan F1 tiap kelas secara terpisah, bukan hanya akurasi total.

- **Frontend/UI:** HTML, CSS, dan JavaScript tanpa framework, dirender Jinja2 dan disajikan langsung oleh FastAPI, dengan Fetch API sebagai jalur pertukaran data. React maupun Vue tidak dipakai karena halamannya hanya berisi form registrasi dan login, satu form untuk menempel link, satu kartu hasil, dan satu halaman riwayat dengan search bar: menambah build step beserta ratusan dependency untuk itu tidak sepadan, dan aplikasinya jadi bisa dibuka tanpa menjalankan proses kedua.

3. Rancangan Fitur Inti

3.1 Penyaringan Bertahap dengan Gerbang Dua Lapis

Fungsi: Menyaring kasus yang sudah jelas memakai model lokal yang murah, lalu meneruskan sisanya ke Gemini. Lapis pertama memeriksa keberadaan media: halaman bergambar atau bervideo selalu naik ke Gemini, berapa pun skor classifier, sebab IndoBERT secara harfiah tidak bisa melihat. Lapis kedua baru membandingkan skor, dan hanya berlaku untuk halaman yang murni teks.

Input Data: Judul dan isi artikel hasil ekstraksi, ditambah penanda apakah halaman itu memuat gambar atau video.

Output/Aksi: Label Hoax, Fakta, atau Tidak Pasti; skor keyakinan pada rentang 0 sampai 100; serta keputusan internal apakah Gemini perlu dipanggil, lengkap dengan alasannya yang dicatat di log.

3.2 Penilaian Visual Langsung oleh Model Multimodal

Fungsi: Menilai isi gambar dan video, bukan sekadar membaca tulisan yang kebetulan tercetak di dalamnya. Perbedaannya penting untuk foto peristiwa: pertanyaan yang perlu dijawab bukan “apa yang tertulis di gambar ini”, melainkan apakah kejadian yang terlihat benar-benar cocok dengan klaim di artikel, dan apakah ada tanda suntingan.

Input Data: File gambar yang di-download dari link hasil scraping, file video yang di-upload lebih dulu lewat Files API, dan teks artikel, ketiganya dikirim dalam satu prompt yang sama.

Output/Aksi: Penilaian yang penjelasannya menyebut isi visual secara spesifik, ditambah catatan modalitas apa saja yang benar-benar ikut diperiksa sehingga pengguna tahu seberapa dalam pemeriksaan yang sudah dilakukan.

3.3 Penelusuran Rujukan Otomatis (RAG)

Fungsi: Mencari entri cek-fakta yang paling dekat maknanya dengan klaim, supaya Gemini menilai berdasar bahan yang diberikan alih-alih mengandalkan ingatan modelnya sendiri.

Input Data: Teks artikel yang sudah dibersihkan, dibandingkan dengan korpus cek-fakta hasil kurasi yang sudah di-encode jadi vektor.

Output/Aksi: Paling banyak tiga entri teratas beserta skor kemiripannya, disisipkan ke prompt sebagai bahan rujukan. Entri yang skornya di bawah ambang dibuang: memberi Gemini rujukan yang tidak nyambung lebih berbahaya daripada tidak memberi rujukan sama sekali, karena modelnya bisa terpancing mengaitkan hal yang tidak berkaitan.

3.4 Agregasi Skor dan Penandaan Ketidakpastian

Fungsi: Menggabungkan dua penilaian yang bisa saja bertentangan, tanpa menyembunyikan perselisihannya dari pengguna.

Input Data: Label dan skor dari IndoBERT, label dan skor dari Gemini, serta daftar rujukan yang dipakai Gemini.

Output/Aksi: Ketika keduanya sepakat, skor akhir dihitung dari 0,4 bagian classifier ditambah 0,6 bagian Gemini. Ketika labelnya berbeda, sistem mengikuti Gemini namun memotong 15 poin, dan bila hasil potongan itu jatuh di bawah 60% labelnya berubah menjadi Tidak Pasti. Satu pengecualian dibuat khusus: Gemini yang menjawab Tidak Pasti karena rujukannya memang kurang tidak dihitung sebagai perselisihan, jadi skornya tidak dipotong, dan alasan “rujukan belum memadai” ditulis apa adanya ke pengguna.

3.5 Akun Pengguna dan Riwayat Pemeriksaan

Fungsi: Memberi tiap pengguna akun pribadi dan riwayat pemeriksaan yang terpisah dari pengguna lain, lengkap dengan search bar untuk menemukan kembali pemeriksaan lama. Search bar hanya ada di halaman riwayat; kolom untuk menempel link di halaman depan adalah form input, bukan search bar.

Input Data: Nama, email, dan password saat registrasi, kemudian email dan password saat login. Pada search bar, pengguna mengetik judul artikel atau nama situs, dan bisa mempersempit hasil dengan filter label (Hoax, Fakta, Tidak Pasti) serta rentang waktu.

Output/Aksi: Daftar riwayat yang tiap barisnya menampilkan judul artikel, label, skor, dan waktu pemeriksaan, diurutkan dari yang terbaru. Password tidak pernah disimpan dalam bentuk asli. Bila tidak ada hasil yang cocok, halaman menampilkan pesan dengan tombol untuk menghapus pencarian, bukan tabel kosong.

4. Alur Data & Cara Kerja

1. **Pengumpulan Data.** Setelah login, pengguna menempel satu link pada form di halaman depan. requests men-download halaman satu kali, lalu newspaper3k membaca HTML hasil download itu (ia tidak mengakses web sendiri) dan menarik judul, isi, nama situs, dan tanggal terbit, sementara langdetect memeriksa bahasanya. Penemuan media memakai HTML yang sama secara berlapis: gambar utama dan link video dari newspaper3k lebih dulu, lalu meta tag og:video bila hasilnya kosong, dan pemindaian pola .mp4 atau .m3u8 di dalam HTML sebagai jaring terakhir. newspaper3k hanya menemukan link, jadi file gambar di-download requests dan file video di-download yt-dlp pada tahap pemrosesan. Halaman yang memblokir pengambilan otomatis atau menyisakan teks di bawah 50 karakter dihentikan di titik ini beserta pesan yang menyebut sebabnya.
2. **Transmisi & Komunikasi.** Browser mengirim objek JSON berisi satu field url ke endpoint POST /api/submissions lewat Fetch API, lalu menerima balasan berupa satu objek JSON yang memuat label, skor, penjelasan, daftar rujukan, dan modalitas yang dinilai. Ke arah luar, backend berbicara HTTPS dengan Gemini API, sedangkan download halaman, gambar, dan video mengikuti protokol yang dipakai server penerbit berita.
3. **Pemrosesan.** IndoBERT menilai teks artikel lebih dulu dan menghasilkan label beserta probabilitasnya. Gerbang keputusan lalu menentukan arah: halaman bergambar atau berveideo langsung diteruskan, sedangkan halaman teks murni hanya diteruskan bila skornya di bawah ambang. Pada jalur yang diteruskan, modul retrieval mencari rujukan,

backend menyusun prompt berisi artikel, rujukan, skor classifier, serta file gambar dan video, lalu Gemini menjawab dalam JSON yang kemudian diurai dan divalidasi. File video yang di-upload ke Google ditunggu sampai berstatus ACTIVE sebelum dipakai, dan blok try/finally memastikan file lokal serta salinan di Google dihapus meski penilaian gagal di tengah jalan. Jawaban yang gagal divalidasi diperlakukan sama seperti panggilan yang gagal.

4. **Eksekusi & Tampilan.** Backend menyimpan dua baris yang terikat ke akun pengguna: satu pada tabel submissions untuk link, judul, teks ekstraksi, link media, dan status; satu lagi pada analysis_results untuk label, skor, penjelasan, rujukan, modalitas, serta rincian skor tiap tahap. Data akun sendiri berada di tabel users. File video tidak pernah masuk database. Response JSON kembali ke browser, yang merender kartu hasil berisi badge berwarna sesuai label, bilah skor, penjelasan, link rujukan yang bisa diklik, dan badge modalitas. Halaman riwayat memuat isinya lewat GET /api/submissions, hanya untuk pengguna yang sedang login, dan menyaringnya sesuai kata kunci dan filter pada search bar.

5. Pengujian & Limitasi

5.1 Metrik Pengujian

Pengujian belum dijalankan, jadi bagian ini baru menetapkan cara menilai dan belum memuat angka hasil. Pertanyaan intinya sederhana: ketika HoaxScan memberi label Hoax atau Fakta, seberapa sering label itu sama dengan kenyataan? Kenyataan diambil dari data uji yang dipisah sebelum fine-tuning dan tidak disentuh sampai evaluasi akhir, dengan pembagian stratified agar proporsi hoax dan fakta sama di setiap bagian.

Dua kesalahan tidak sama beratnya. Hoax yang lolos dengan label Fakta bisa membuat pengguna ikut menyebarkannya karena merasa sudah mengecek, sedangkan berita benar yang tertandai Hoax hanya merepotkan. Karena itu recall kelas hoax menjadi angka pertama yang dibaca, dan akurasi total hanya pelengkap. Pada data yang artikel faktanya jauh lebih banyak, model bisa mencapai akurasi tinggi dengan menebak Fakta terus.

Aspek	Yang diukur	Cara mengukur	Acuan keberhasilan
Ketepatan label	Recall kelas hoax	Confusion matrix pada data uji, dengan hoax sebagai kelas positif. Hoax yang berlabel Fakta dihitung sebagai kesalahan paling mahal.	Tidak di bawah 92,8%, yaitu recall hoax dari confusion matrix Fathin dkk. yang dipakai sebagai rujukan awal.
	Precision, F1 tiap kelas, dan macro-F1	Dihitung dari confusion matrix yang sama. F1 hoax dan F1 fakta dilaporkan terpisah.	Ditetapkan tim setelah baseline IndoBERT tanpa Gemini selesai diukur.
Peran Gemini	Selisih hasil hybrid dan	Data uji yang sama dijalankan dua kali, sekali lewat jalur	Hybrid lebih baik daripada IndoBERT

	IndoBERT saja	penuh dan sekali hanya IndoBERT, lalu recall hoax dan F1 dibandingkan.	saja. Kalau tidak, panggilan ke Gemini tidak sepadan.
Ketidakpastian	Porsi label Tidak Pasti dan akurasi pada sisanya	Hitung persentase hasil berlabel Tidak Pasti, lalu hitung akurasi hanya pada hasil berlabel Hoax atau Fakta.	Akurasi pada kasus yang diputuskan lebih tinggi daripada akurasi keseluruhan. Ambang porsi Tidak Pasti ditentukan tim.
Kalibrasi skor	Kecocokan confidence score dengan kenyataan	Kelompokkan hasil per rentang skor (misalnya 60 sampai 69 dan 70 sampai 79), lalu bandingkan skor rata-rata dengan persentase label yang benar di tiap rentang.	Skor 90 seharusnya benar sekitar 9 dari 10 kali. Selisihnya dicatat per rentang.
Generalisasi	Hasil pada link di luar dataset	Kumpulkan link dari situs yang tidak ada di dataset, misalnya media daerah dan blog, beri label manual dengan mencocokkannya ke Turnbackhoax, lalu hitung metrik yang sama.	Penurunan dibanding data uji dataset dicatat sebagai ukuran bias sumber.
Multimodal	Hasil pada link bergambar dan bervideo	Susun set kecil link berisi foto yang tidak sesuai peristiwa atau video yang dipotong konteksnya dan sudah terbukti hoax, lalu periksa apakah label dan penjelasan menyebut isi visualnya.	Metrik sama seperti di atas, dilaporkan terpisah dari set teks murni.
Kualitas penjelasan	Penjelasan dan sumber rujukan	Periksa manual satu sampel hasil. Tiap sumber harus bisa dibuka dan relevan dengan klaim, dan penjelasan harus menyebut klaim yang spesifik.	Skor 0 sampai 2 per hasil, tanpa satu pun sumber fiktif.
Konsistensi	Label yang sama untuk link yang sama	Kirim ulang sejumlah link yang sama beberapa kali dan hitung berapa yang labelnya berubah.	Label tidak berubah antar-ulang, kecuali ada penyebab yang bisa dijelaskan.
Kecepatan	Response time per jalur	Ukur dari klik Periksa sampai kartu hasil tampil, terpisah	Di bawah 5 detik tanpa media dan di bawah 15

		untuk link teks murni, bergambar, dan bervideo.	detik bergambar (target awal, belum pernah diukur). Target video ditentukan tim.
Ketahanan scraping	Keberhasilan mengambil isi halaman	Jalankan kumpulan link dari beragam situs, lalu hitung yang berhasil, yang diblokir, dan yang isinya terpotong dibanding halaman asli.	Setiap kegagalan berujung pada pesan error yang menyebut sebabnya, tidak berhenti diam-diam.
Fallback	Perilaku saat Gemini gagal	Matikan API key atau habiskan kuota di lingkungan uji, lalu kirim sejumlah link.	Hasil tetap keluar dari IndoBERT beserta alasannya, tanpa crash.

Tabel 1. Kriteria penilaian HoaxScan. Kolom acuan diisi angka setelah baseline terukur.

Hasil tiap kriteria dicatat per versi model dan per versi prompt Gemini. Dengan begitu, setiap kali IndoBERT di-fine-tune ulang atau prompt diubah, angkanya bisa dibandingkan langsung dengan versi sebelumnya.

5.2 Limitasi Saat Ini

- **Belum ada hasil uji.** Semua angka performa di laporan ini berasal dari paper rujukan, bukan dari IndoBERT kami. Jalur video ke Gemini juga belum pernah terbukti berjalan sampai selesai.
- **Bias dataset.** Artikel fakta hanya bersumber dari tiga media (CNN Indonesia, Kompas, Tempo) dan artikel hoax dari satu situs klarifikasi (Turnbackhoax), sehingga model bisa belajar mengenali gaya penulisan sumber alih-alih kebenaran isinya. Berita benar dari situs kecil berisiko ditandai Hoax. Dataset ini juga berjudul berita politik, jadi topik lain seperti kesehatan belum tentu terwakili.
- **Ekstraksi teks.** newspaper3k memotong halaman panjang (pada halaman Wikipedia yang kami coba, hanya 4.720 dari 20.785 karakter yang terbaca) dan tidak dirawat sejak 2018. Situs yang memblokir pengambilan otomatis tidak bisa dinilai.
- **Ketergantungan pada Gemini.** Kuota free tier terbatas. Begitu habis atau gagal, sistem mundur ke IndoBERT yang tidak bisa melihat gambar maupun video, sehingga hasilnya kurang meyakinkan. Data yang dikirim di free tier juga bisa dibaca human reviewer Google.
- **Rujukan RAG.** Klaim baru yang belum ada di korpus cek-fakta tidak akan menemukan rujukan yang cocok, dan hasilnya cenderung Tidak Pasti.
- **Cakupan.** Hanya Bahasa Indonesia. Tidak ada reverse image search maupun deteksi deepfake, jadi foto lama yang dipakai ulang atau video hasil rekayasa canggih hanya dinilai dari apa yang bisa Gemini lihat dan cocokkan dengan klaim.
- **Bukan putusan akhir.** Label hanyalah alat bantu penyaringan, dan kasus penting tetap perlu verifikasi manual.